Воспроизведение: Rethinking the Value of Network Pruning

Liu, Sun, Zhou, Huang, Darrell. ICLR 2019, arXiv:1810.05270. Отчёт собран из CSV, числа не переписывались вручную.

Тезис

Для структурированного прунинга дообучение унаследованных весов не лучше, чем обучение той же архитектуры с нуля при сопоставимом бюджете. Ценность прунинга — в архитектуре. Нерегулярный magnitude-прунинг на высокой разреженности — исключение. ImageNet в эту работу не входит.

Протокол

Один цикл обучения. База 160 эпох, SGD Nesterov, momentum 0.9, weight decay 1e-4, batch 128, lr 0.1, спады в 50% и 75% эпох. Fine-tune: 40 эпох, постоянный lr. Scratch-E: 160 эпох, инициализация He. Scratch-B (cap 2×): E_B = 4 * round(160 * min(2, F_L/F_P) / 4). Стоимость fine-tune в сравнение бюджетов не входит. FLOPs в таблицах — это MAC, без BN, ReLU, пулинга и сложений. Отчётная точность — последняя эпоха, не лучший чекпоинт.

Замороженные гиперпараметры

precision=bf16, lr_ft=0.001, lambda VGG=0.0001, lambda ResNet=1e-05, hash=52a438d6f5dbe86a.

Отклонения от статьи

Конфиги L1-V16A*, L1-R56A*, L1-R56B* помечены звёздочкой: точные слои и доли в PDF не заданы. Доля каналов ResNet считается только по внутренним каналам блоков и не сопоставима с Table 4. Scratch-B ограничен двумя разами; для SL-R56-80 есть отдельный прогон без потолка (SBU). Рисунок 3 построен на VGG-19, guided — только на CIFAR-10. Три сида вместо пяти. Протокол fine-tune для Slimming в PDF не описан; здесь он тот же, что и для остальных методов.

Dev-split, не тест

dev-V16.BASE.s0: val 92.6800 статья 93.63 gap -0.9500

dev-V19.BASE.s0: val 92.5800 статья 93.53 gap -0.9500

dev-R56.BASE.s0: val 92.2000 статья 93.14 gap -0.9400

dev-V19C100.BASE.s0: val 70.3600 статья 72.63 gap -2.2700

dev-V16.BASE.fp32.s0: val 92.8200 статья 93.63 gap -0.8100

Тест, mean±std по сидам

L1-R56A FT cifar10: 92.42±0.42 n=2 params=597526 macs=87054976

L1-R56A SB cifar10: 92.25±0.80 n=2 params=597526 macs=87054976

L1-R56A SE cifar10: 91.70±0.87 n=2 params=597526 macs=87054976

L1-R56B FT cifar10: 91.14±0.33 n=2 params=360142 macs=63185536

L1-R56B SB cifar10: 92.28±0.59 n=2 params=360142 macs=63185536

L1-R56B SE cifar10: 91.84±0.34 n=2 params=360142 macs=63185536

L1-V16A FT cifar10: 92.89±0.33 n=2 params=5261866 macs=206146048

L1-V16A SB cifar10: 93.23±0.12 n=2 params=5261866 macs=206146048

L1-V16A SE cifar10: 93.08±0.09 n=2 params=5261866 macs=206146048

R56 BASE cifar10: 93.03±0.13 n=2 params=853018 macs=125485696

R56 BASES cifar10: 93.07±0.36 n=2 params=853018 macs=125485696

SL-R56-40 FT cifar10: 92.00 n=1 params=448438 macs=84492928

SL-R56-40 SB cifar10: 92.87 n=1 params=448438 macs=84492928

SL-R56-40 SE cifar10: 92.47 n=1 params=448438 macs=84492928

SL-R56-60 FT cifar10: 90.88±0.56 n=2 params=273942 macs=60549760

SL-R56-60 SB cifar10: 92.59±0.36 n=2 params=273942 macs=60549760

SL-R56-60 SE cifar10: 91.18±0.69 n=2 params=273942 macs=60549760

SL-R56-80 FT cifar10: 86.54 n=1 params=121482 macs=35334784

SL-R56-80 SB cifar10: 90.91 n=1 params=121482 macs=35334784

SL-R56-80 SE cifar10: 90.36 n=1 params=121482 macs=35334784

SL-V19-30 SE cifar10: 92.87 n=1 params=9514008 macs=261984102

SL-V19-50 SE cifar10: 93.19 n=1 params=4960913 macs=200462804

SL-V19-70 FT cifar10: 92.73±0.01 n=2 params=2024834 macs=162499802

SL-V19-70 SB cifar10: 93.41±0.22 n=2 params=2024834 macs=162499802

SL-V19-70 SE cifar10: 93.12±0.33 n=2 params=2024834 macs=162499802

UF-R56-40 UF cifar10: 92.19 n=1 params=453328 macs=65544832

UF-R56-60 UF cifar10: 89.51 n=1 params=278818 macs=40163968

UF-R56-80 UF cifar10: 88.14 n=1 params=119464 macs=16718464

UF-V19-30 UF cifar10: 92.17 n=1 params=9519543 macs=188994314

UF-V19-50 UF cifar10: 91.31 n=1 params=4970091 macs=99150726

UF-V19-70 UF cifar10: 90.62 n=1 params=2031499 macs=40458574

UN-R56-95 FT cifar10: 87.30 n=1 params=47129 macs=11130176

UN-R56-95 SB cifar10: 88.99 n=1 params=47129 macs=11130176

UN-R56-95 SE cifar10: 88.13 n=1 params=47129 macs=11130176

UN-V19-80 FT cifar10: 92.90 n=1 params=4019914 macs=209242052

UN-V19-80 SB cifar10: 93.55 n=1 params=4019914 macs=209242052

UN-V19-80 SE cifar10: 93.27 n=1 params=4019914 macs=209242052

UN-V19-95 FT cifar10: 92.56 n=1 params=1017082 macs=103076996

UN-V19-95 SB cifar10: 93.01 n=1 params=1017082 macs=103076996

UN-V19-95 SE cifar10: 92.87 n=1 params=1017082 macs=103076996

V16 BASE cifar10: 92.84±0.41 n=2 params=14724042 macs=313201664

V19 BASE cifar10: 92.84 n=1 params=20035018 macs=398136320

V19 BASES cifar10: 92.68±0.20 n=2 params=20035018 macs=398136320

Гипотезы

H1 (Scratch-B и Scratch-E против fine-tune): подтверждена.

L1-V16A: SB−FT 0.34 п.п., SE−FT 0.18 п.п.

L1-R56A: SB−FT -0.18 п.п., SE−FT -0.72 п.п.

L1-R56B: SB−FT 1.14 п.п., SE−FT 0.70 п.п.

SL-V19-70: SB−FT 0.68 п.п., SE−FT 0.39 п.п.

SL-R56-60: SB−FT 1.72 п.п., SE−FT 0.30 п.п.

H1c (winning ticket против Scratch-E при lr 0.1): не проверено.

L1-V16A: WT−SE нет прогона п.п.

L1-R56A: WT−SE нет прогона п.п.

L1-R56B: WT−SE нет прогона п.п.

H2, доля пар с E_B>160, где SB−SE ≥ +0.1 п.п.: подтверждена (13/15).

H2, кривая SL-R56 40/60/80, Scratch-B cap 2×: подтверждена.

SL-R56-40: SB−FT 0.87 п.п.

SL-R56-60: SB−FT 1.72 п.п.

SL-R56-80: SB−FT 4.37 п.п.

SBU−FT на SL-R56-80 (без потолка, контроль): нет прогона п.п.

H3, VGG Slimming против uniform: подтверждена.

VGG 30%: SL−UF 0.70 п.п.

VGG 50%: SL−UF 1.88 п.п.

VGG 70%: SL−UF 2.27 п.п.

H3, guided: не проверено.

GD 30%: GD−UF нет прогона, GD−SL нет прогона

GD 50%: GD−UF нет прогона, GD−SL нет прогона

GD 70%: GD−UF нет прогона, GD−SL нет прогона

H3, ResNet |SL−UF|: опровергнута.

ResNet 40%: |SL−UF| 0.28 п.п.

ResNet 60%: |SL−UF| 2.16 п.п.

ResNet 80%: |SL−UF| 2.22 п.п.

H4: опровергнута. UN-V19-80 SB−FT 0.65 п.п., UN-R56-95 SB−FT 1.69 п.п.

Доли сохранённых каналов, сид 1, Scratch-E

L1-R56A: 0.688 0.688 0.703 размах стадий 0.016

L1-R56B: 0.688 0.406 0.406 размах стадий 0.281

L1-V16A: 0.750 1.000 1.000 0.500 0.500 поздние стадии сильнее: True

SL-R56-40: 0.764 0.819 0.451 размах стадий 0.368

SL-R56-60: 0.625 0.590 0.253 размах стадий 0.372

SL-R56-80: 0.493 0.267 0.104 размах стадий 0.389

SL-V19-30: 0.789 0.980 0.868 0.704 0.572 поздние стадии сильнее: True

SL-V19-50: 0.703 0.973 0.786 0.518 0.268 поздние стадии сильнее: True

SL-V19-70: 0.688 0.973 0.773 0.184 0.071 поздние стадии сильнее: True

UN-R56-95: 1.000 1.000 1.000 размах стадий 0.000

UN-V19-80: 1.000 1.000 1.000 1.000 1.000 поздние стадии сильнее: False

UN-V19-95: 1.000 1.000 1.000 1.000 1.000 поздние стадии сильнее: False

Латентность GPU

Замеры после обучения, FP32 с выключенным TF32 и FP16, batch 1 и 256. Нерегулярные маски не мерялись: плотное ядро от маски не ускоряется.

L1-R56A.SE.s1 bs=1 fp32: median 7.3007 ms, IQR 0.1806 ms

L1-R56B.SE.s1 bs=1 fp32: median 6.7155 ms, IQR 0.2405 ms

L1-V16A.SE.s1 bs=1 fp32: median 1.5483 ms, IQR 0.1404 ms

R56.BASE.s1 bs=1 fp32: median 7.4294 ms, IQR 0.4049 ms

SL-R56-40.SE.s1 bs=1 fp32: median 6.9226 ms, IQR 0.2388 ms

SL-R56-60.SE.s1 bs=1 fp32: median 6.4620 ms, IQR 0.1940 ms

SL-R56-80.SE.s1 bs=1 fp32: median 6.2457 ms, IQR 0.2063 ms

SL-V19-30.SE.s1 bs=1 fp32: median 2.4435 ms, IQR 0.0244 ms

SL-V19-50.SE.s1 bs=1 fp32: median 1.9877 ms, IQR 0.0973 ms

SL-V19-70.SE.s1 bs=1 fp32: median 2.1959 ms, IQR 0.0971 ms

V16.BASE.s1 bs=1 fp32: median 2.6692 ms, IQR 0.1509 ms

V19.BASE.s1 bs=1 fp32: median 3.6164 ms, IQR 0.0767 ms

L1-R56A.SE.s1 bs=256 fp32: median 14.3752 ms, IQR 0.0941 ms

L1-R56B.SE.s1 bs=256 fp32: median 10.5903 ms, IQR 0.1135 ms

L1-V16A.SE.s1 bs=256 fp32: median 13.0195 ms, IQR 0.3466 ms

R56.BASE.s1 bs=256 fp32: median 16.4764 ms, IQR 0.3418 ms

SL-R56-40.SE.s1 bs=256 fp32: median 13.1693 ms, IQR 0.2546 ms

SL-R56-60.SE.s1 bs=256 fp32: median 11.8687 ms, IQR 0.1413 ms

SL-R56-80.SE.s1 bs=256 fp32: median 9.4698 ms, IQR 0.2580 ms

SL-V19-30.SE.s1 bs=256 fp32: median 16.6517 ms, IQR 0.1035 ms

SL-V19-50.SE.s1 bs=256 fp32: median 13.8782 ms, IQR 0.2970 ms

SL-V19-70.SE.s1 bs=256 fp32: median 11.5332 ms, IQR 0.2589 ms

V16.BASE.s1 bs=256 fp32: median 17.8216 ms, IQR 0.3155 ms

V19.BASE.s1 bs=256 fp32: median 20.9813 ms, IQR 0.3422 ms

L1-R56A.SE.s1 bs=1 fp16: median 8.3620 ms, IQR 0.2811 ms

L1-R56B.SE.s1 bs=1 fp16: median 7.7955 ms, IQR 0.1509 ms

L1-V16A.SE.s1 bs=1 fp16: median 1.7489 ms, IQR 0.0514 ms

R56.BASE.s1 bs=1 fp16: median 7.0948 ms, IQR 0.2087 ms

SL-R56-40.SE.s1 bs=1 fp16: median 8.1008 ms, IQR 0.1800 ms
SL-R56-60.SE.s1 bs=1 fp16: median 8.2744 ms, IQR 0.0988 ms
SL-R56-80.SE.s1 bs=1 fp16: median 7.6062 ms, IQR 0.2175 ms
SL-V19-30.SE.s1 bs=1 fp16: median 2.7325 ms, IQR 0.0393 ms
SL-V19-50.SE.s1 bs=1 fp16: median 2.6599 ms, IQR 0.0410 ms
SL-V19-70.SE.s1 bs=1 fp16: median 2.7753 ms, IQR 0.0772 ms
V16.BASE.s1 bs=1 fp16: median 1.7741 ms, IQR 0.0535 ms
V19.BASE.s1 bs=1 fp16: median 2.1594 ms, IQR 0.0265 ms
L1-R56A.SE.s1 bs=256 fp16: median 8.4240 ms, IQR 0.1644 ms
L1-R56B.SE.s1 bs=256 fp16: median 8.8090 ms, IQR 0.1531 ms
L1-V16A.SE.s1 bs=256 fp16: median 2.5098 ms, IQR 0.0130 ms
R56.BASE.s1 bs=256 fp16: median 7.1150 ms, IQR 0.1394 ms
SL-R56-40.SE.s1 bs=256 fp16: median 8.1373 ms, IQR 0.0622 ms
SL-R56-60.SE.s1 bs=256 fp16: median 7.8808 ms, IQR 0.0673 ms
SL-R56-80.SE.s1 bs=256 fp16: median 7.7180 ms, IQR 0.1221 ms
SL-V19-30.SE.s1 bs=256 fp16: median 4.4022 ms, IQR 0.0646 ms
SL-V19-50.SE.s1 bs=256 fp16: median 4.0676 ms, IQR 0.0991 ms
SL-V19-70.SE.s1 bs=256 fp16: median 3.2819 ms, IQR 0.0287 ms
V16.BASE.s1 bs=256 fp16: median 3.3537 ms, IQR 0.0264 ms
V19.BASE.s1 bs=256 fp16: median 4.1182 ms, IQR 0.0446 ms

Бюджет

G1: секунд на эпоху {'resnet56': 10.141712714001187, 'vgg16': 3.847704148498451, 'vgg19': 4.610895606001577}, phi=1.0, K=1. Два прогона на одной 5070 Ti не обогнали сумму эпох, очередь шла в один поток.

Допуск 16.79456621567408 ч, смета полного включённого набора 26.127109900332417 ч. Включено 79, вырезано 102. Фаза 3 (сиды 2–3 для P2a и весь P2b: CIFAR-100, guided, winning ticket, SBU, нерегулярный ResNet 80%) не запускалась. Сид 3 у основных конфигов тоже вырезан, поэтому H1 посчитана по двум сидам.

Инварианты

Проверки агрегатора прошли.