Отчёт о воспроизведении результатов статьи

Rethinking the Value of Network Pruning (Liu, Sun, Zhou, Huang, Darrell; ICLR 2019, arXiv:1810.05270)

1. Цель и что воспроизводим

Статья утверждает, что для структурированного прунинга дообучение унаследованных весов не лучше, чем обучение той же архитектуры с нуля при сопоставимом бюджете. Найденная прунингом архитектура, а не веса, даёт выигрыш. Для нерегулярного прунинга авторы видят исключение на ImageNet и при высокой разреженности. Мы проверяем это на CIFAR и формулируем четыре гипотезы.

№	Гипотеза	Критерий
H1	Для структурированного прунинга обучение с нуля не хуже fine-tune	SB−FT ≥ −0.2 п.п. хотя бы в 4 из 5 конфигов и SE−FT ≥ −0.3 п.п. хотя бы в 3 из 5; опровержение — SB < FT − 0.5 в двух и более
H1c	Winning ticket не лучше случайной инициализации при lr 0.1	|WT−SE| < 0.3 п.п. хотя бы в 2 из 3 конфигов L1
H2	Дольше обучение (Scratch-B) помогает; выигрыш растёт с долей прунинга	SB−SE ≥ +0.1 в 70% пар с E_B > 160; SL-R56 SB−FT растёт с 40% до 80% и ≥ +1.0 на 80%
H3	Найденная архитектура лучше uniform на VGG, на ResNet близка к ней	VGG: SL−UF ≥ +0.2 в 2 из 3; guided близок к SL; ResNet: |SL−UF| < 0.3 в 2 из 3
H4	Нерегулярный прунинг: Scratch-B не хуже при 80%, хуже при 95%	UN-V19-80 SB−FT ≥ −0.3 и UN-R56-95 SB−FT ≤ −0.5

2. Экспериментальная установка

Данные: CIFAR-10 (основная часть). Сети: VGG-16, VGG-19 с BatchNorm и одним линейным слоем, ResNet-56 с шорткатом типа A (zero-padding). Методы: L1-norm filter pruning, Network Slimming, нерегулярный magnitude pruning (Han), uniform-baseline с тем же числом параметров.

Режимы одной конфигурации: база (160 эпох) → прунинг → Fine-tune (40 эпох, постоянный lr) | Scratch-E (160 эпох, He-инициализация) | Scratch-B. Для Scratch-B число эпох $E_B = 4 \cdot \mathrm{round}(160 \cdot \kappa / 4)$, где $\kappa = \min(2, F_L/F_P)$ и F — число MAC большой и малой сети; расписание lr растягивается пропорционально (спады на 50% и 75%). Потолок $\kappa = 2$ оставлен как в статье для ImageNet; на CIFAR это ограничение мы вводим сами и называем Scratch-B (cap 2×).

Общий цикл: SGD с Нестеровым, momentum 0.9, weight decay 1e-4, batch 128, lr 0.1, аугментация — случайный кроп с отступом 4 и горизонтальный флип, независимо для каждой картинки. Обучение в bf16, оценка в FP32 без TF32. В отчёт идёт точность последней эпохи; тест читается один раз на прогон. Выбор по лучшей эпохе на тесте не делается.

Гиперпараметры заморожены на dev-сплите (45 000 / 5 000, стратифицированно) и зафиксированы в conf/frozen_hparams.json, хэш 52a438d6f5dbe86a: precision=bf16, lr_ft=0.001, λ Slimming для VGG 0.0001, для ResNet 1e-05. После заморозки гиперпараметры не подбирались.

Прунинг: L1 — доля каналов по слою; для ResNet режутся только внутренние каналы блока (conv1/bn1), поток остатка не трогается. Slimming: L1-штраф на γ BatchNorm

добавляется к градиенту в fp32, глобальный top-k по |γ|. Нерегулярный: глобальный one-shot top-k по |w| только для весов свёрток; маска применяется к градиенту и к весам после шага. Uniform: одна доля на все слои, подобранная так, чтобы число параметров совпало с архитектурой Slimming того же сида.

Железо: одна RTX 5070 Ti (sm_120), PyTorch 2.11 + CUDA 12.8, без torch.compile. Две обучающие программы одновременно на этой карте не давали выигрыша, поэтому очередь шла в один поток.

3. Проверка базовых сетей (dev-сплит)

Прогон	Сеть	Данные	val, %	Статья, %	Разница
dev-V16.BASE.s0	vgg16	cifar10	92.68	93.63	-0.95
dev-V19.BASE.s0	vgg19	cifar10	92.58	93.53	-0.95
dev-R56.BASE.s0	resnet56	cifar10	92.20	93.14	-0.94
dev-V19C100.BASE.s0	vgg19	cifar100	70.36	72.63	-2.27
dev-V16.BASE.fp32.s0	vgg16	cifar10	92.82	93.63	-0.81

На dev-сплите (45k обучающих картинок) базовые сети на 0.8–0.95 п.п. ниже статьи на CIFAR-10 и на 2.3 п.п. ниже на CIFAR-100 (VGG-19). Часть разрыва — меньший обучающий набор; на полном сплите (тест, last epoch) базы такие: VGG-16 92.84, VGG-19 92.84, ResNet-56 93.03 против 93.63, 93.53, 93.14 в статье. bf16 против FP32 на VGG-16 даёт разницу −0.14 п.п., это внутри порога 0.3, поэтому оставлен bf16. Причину отставания от статьи мы не искали; сравнение методов идёт внутри одного нашего цикла.

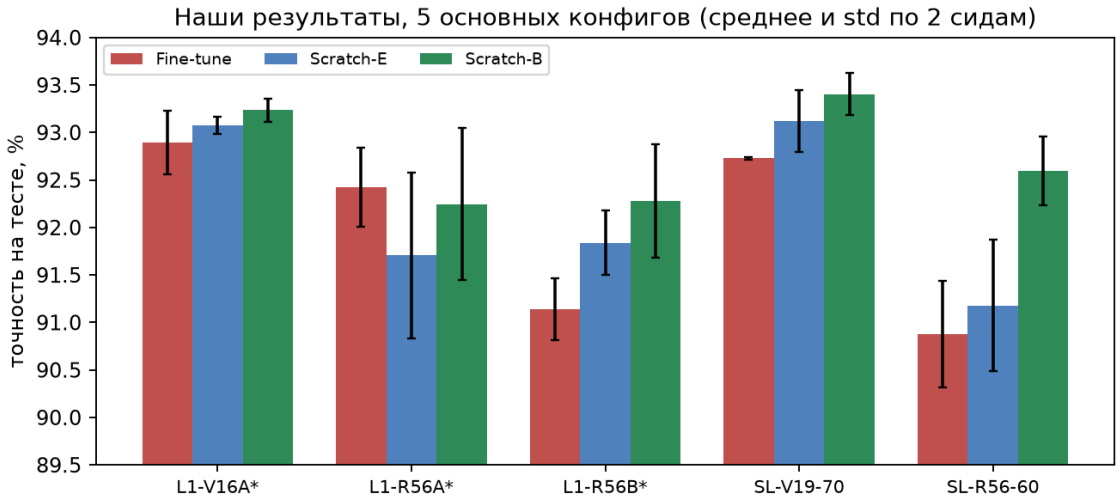
4. Результаты

4.1. L1-norm filter pruning (таблица 1 статьи)

Строка	Исходная	Fine-tune	Scratch-E	Scratch-B	SE−FT	SB−FT
Статья VGG-16-A	93.63	93.41	93.62	93.78	+0.21	+0.37
Статья ResNet-56-A	93.14	92.97	92.96	93.09	-0.01	+0.12
Статья ResNet-56-B	93.14	92.67	92.54	93.05	-0.13	+0.38
Наша VGG-16-A*	92.84 ± 0.41	92.89 ± 0.33	93.08 ± 0.09	93.23 ± 0.12	+0.18	+0.34
Наша ResNet-56-A*	93.03 ± 0.13	92.42 ± 0.42	91.70 ± 0.87	92.25 ± 0.80	-0.72	-0.18
Наша ResNet-56-B*	93.03 ± 0.13	91.14 ± 0.33	91.84 ± 0.34	92.28 ± 0.59	+0.70	+1.14

Звёздочка: конфигурации *-A и *-B в PDF заданы ссылкой на Li et al., без слоёв и долей, поэтому мы выбрали их сами [ДОПУЩЕНИЕ]: VGG-16-A* режет 50% первого и слоёв 8–13; ResNet-56-A* режет 30% внутренних каналов всех блоков; ResNet-56-B* режет 30% в стадии 1 и 60% в стадиях 2–3. Поэтому абсолютные числа строк статьи и наших несопоставимы, сравнивать нужно разности SE−FT и SB−FT. Наши: n = 2 сида (± — std по двум сидам). Статьи: 5 сидов.

VGG-16-A*: разности близки к статье (у статьи SE−FT +0.21, SB−FT +0.37; у нас +0.18 и +0.34). ResNet-56-A*: у статьи SE−FT −0.01, SB−FT +0.12; у нас -0.72 и -0.18. ResNet-56-B*: у статьи −0.13 и +0.38; у нас +0.70 и +1.14. Итого Scratch-B не хуже fine-tune в двух конфигах из трёх с запасом, в третьем (A*) проигрыш внутри порога шума. Scratch-E соответствует статье только на VGG-16-A*.



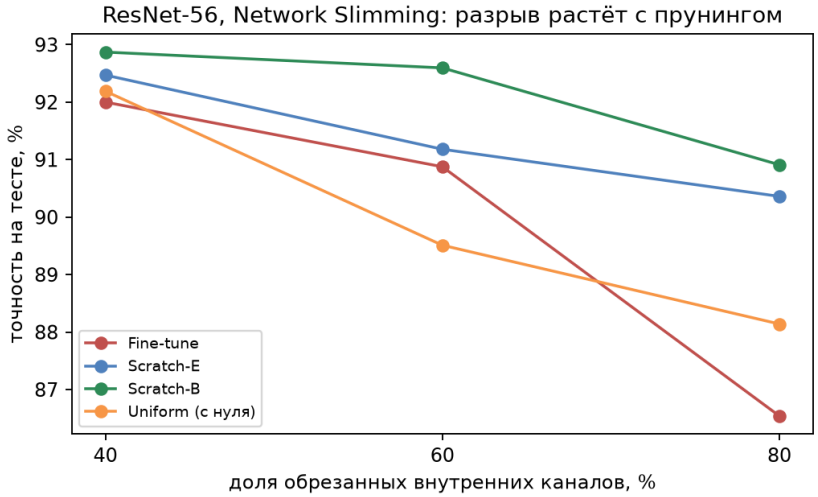
4.2. Network Slimming (таблица 4 статьи)

Строка	Исходная	Fine-tune	Scratch-E	Scratch-B	SE−FT	SB−FT
Статья VGG-19 70%	93.53	93.60	93.30	93.81	-0.30	+0.21
Наша VGG-19 70%	92.68 ± 0.20	92.73 ± 0.01	93.12 ± 0.33	93.41 ± 0.22	+0.39	+0.68
Наша ResNet-56 60%	93.07 ± 0.36	90.88 ± 0.56	91.18 ± 0.69	92.59 ± 0.36	+0.31	+1.72
Наша ResNet-56 40% (n=1)	93.07 ± 0.36	92.00	92.47	92.87	+0.47	+0.87
Наша ResNet-56 80% (n=1)	93.07 ± 0.36	86.54	90.36	90.91	+3.82	+4.37

VGG-19 с 70% совпадает с условиями статьи (доля каналов считается по всей сети). Для ResNet-56 доля считается только по внутренним каналам блоков [ДОПУЩЕНИЕ], в статье для ResNet-56 Slimming не оценивался, там PreResNet-164 и DenseNet-40, которых у нас нет. Строки ResNet-56 — наши собственные точки.

VGG-19, 70%: у статьи SB−FT = +0.21, SE−FT = −0.30; у нас SB−FT = +0.68, SE−FT =

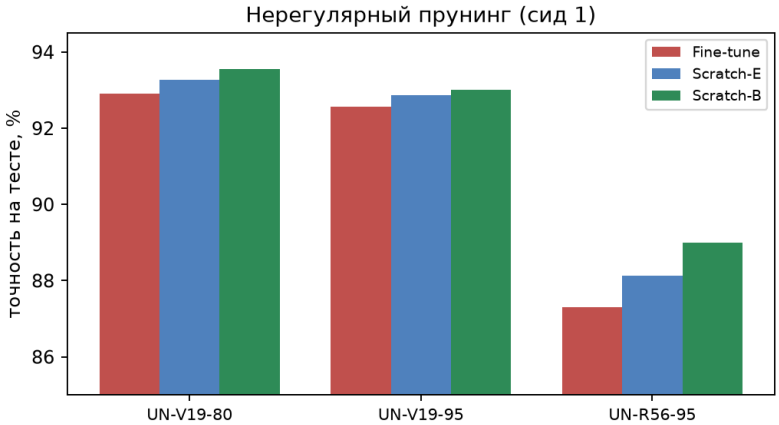
+0.39. SB−FT того же знака, но больше; SE−FT у нас положительная, у статьи отрицательная. На ResNet-56 разрыв растёт с долей прунинга и на 80% достигает +4.37 п.п. (n=1). Fine-tune на 80% теряет относительно базы больше 6 п.п.



4.3. Нерегулярный magnitude pruning (таблица 6 статьи)

Строка	Исходная	Fine-tune	Scratch-E	Scratch-B	SE−FT	SB−FT
Статья VGG-19 80%	93.50	93.52	93.71	93.64	+0.19	+0.12
Статья VGG-19 95%	93.50	93.34	93.21	93.63	-0.13	+0.29
Наша VGG-19 80% (n=1)	92.84	92.90	93.27	93.55	+0.37	+0.65
Наша VGG-19 95% (n=1)	92.84	92.56	92.87	93.01	+0.31	+0.45
Наша ResNet-56 95% (n=1)	93.03 ± 0.13	87.30	88.13	88.99	+0.83	+1.69

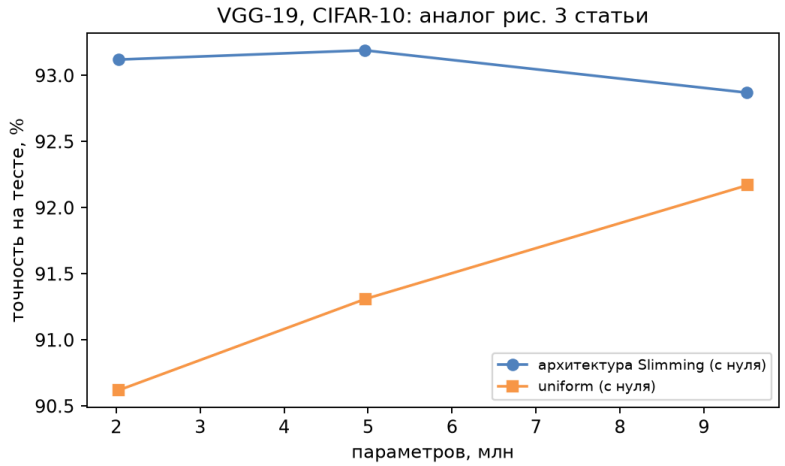
Для VGG-19 сохраняется картина статьи: Scratch-B не хуже fine-tune и на 95%. Для ResNet-56 на 95% (47 тыс. параметров) Scratch-B выше fine-tune на 1.7 п.п. В статье на PreResNet-110 при 95% fine-tune лучше. Возможная причина — недообучение fine-tune за 40 эпох на очень разреженной сети с постоянным lr 0.001; мы это не проверяли.



4.4. Найденная архитектура против uniform (раздел 5 статьи)

Конфиг	Параметров Slimming	Slimming, с нуля	Параметров uniform	Uniform, с нуля	SL−UF
VGG-19 30%	9514008	92.87	9519543	92.17	+0.70
VGG-19 50%	4960913	93.19	4970091	91.31	+1.88
VGG-19 70%	2024834	93.12 ± 0.33	2031499	90.62	+2.50
ResNet-56 40%	448438	92.47	453328	92.19	+0.28
ResNet-56 60%	273942	91.18 ± 0.69	278818	89.51	+1.67
ResNet-56 80%	121482	90.36	119464	88.14	+2.22

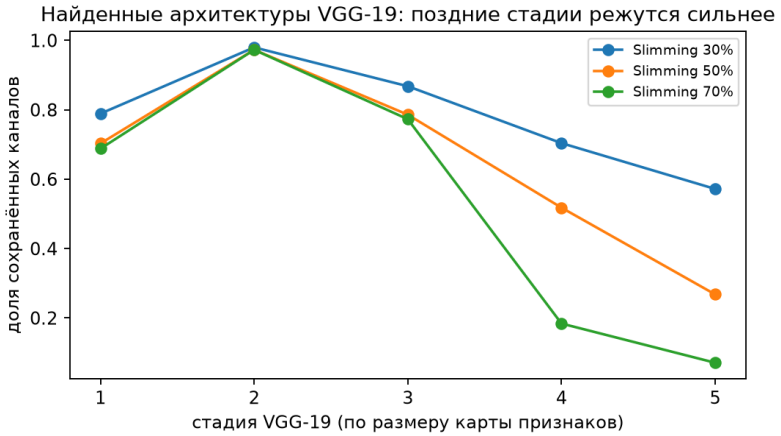
Число параметров uniform подгоняется под архитектуру Slimming того же сида с допуском до 2% (фактически 0.06–1.8%). Для каждой точки по 1 сиду на uniform, поэтому разности без доверительного интервала. VGG-19: Slimming выигрывает 0.70, 1.88, 2.27 п.п., что воспроизводит рис. 3 статьи (слева). Для ResNet-56 мы видим разрыв 2.2 п.п. на 60% и 80%, а статья для ResNet-подобных сетей (PreResNet-164, DenseNet-40) показывает паритет и объясняет его почти равномерным распределением прунинга по стадиям (таблицы 18–20).



Доли сохранённых каналов по стадиям (сид 1, Scratch-E):

Конфиг	Доли по стадиям	Комментарий
L1-R56A	0.688 0.688 0.703	размах по стадиям 0.02
L1-R56B	0.688 0.406 0.406	размах по стадиям 0.28
L1-V16A	0.750 1.000 1.000 0.500 0.500	поздние стадии режутся сильнее
SL-R56-40	0.764 0.819 0.451	размах по стадиям 0.37
SL-R56-60	0.625 0.590 0.253	размах по стадиям 0.37
SL-R56-80	0.493 0.267 0.104	размах по стадиям 0.39
SL-V19-30	0.789 0.980 0.868 0.704 0.572	поздние стадии режутся сильнее
SL-V19-50	0.703 0.973 0.786 0.518 0.268	поздние стадии режутся сильнее
SL-V19-70	0.688 0.973 0.773 0.184 0.071	поздние стадии режутся сильнее

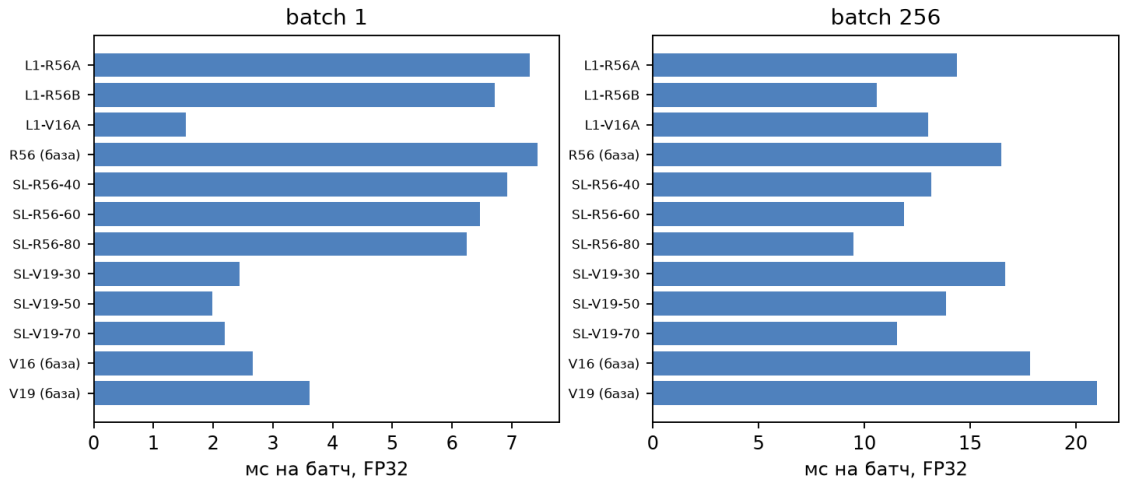
VGG-19 с Slimming режет поздние стадии и почти не трогает ранние: так же, как в таблице 21 статьи. ResNet-56 с нашим λ = 1e-5 получает стадийный размах 0.37–0.39 (а не «почти равномерный»), поэтому его паритет с uniform не ожидается.



4.5. Латентность на GPU

Модель (сид 1)	bs 1 FP32, мс	bs 1 FP16, мс	bs 256 FP32, мс	bs 256 FP16, мс
L1-R56A (Scratch-E)	7.30	8.36	14.38	8.42
L1-R56B (Scratch-E)	6.72	7.80	10.59	8.81
L1-V16A (Scratch-E)	1.55	1.75	13.02	2.51
R56 (база)	7.43	7.09	16.48	7.12
SL-R56-40 (Scratch-E)	6.92	8.10	13.17	8.14
SL-R56-60 (Scratch-E)	6.46	8.27	11.87	7.88
SL-R56-80 (Scratch-E)	6.25	7.61	9.47	7.72
SL-V19-30 (Scratch-E)	2.44	2.73	16.65	4.40
SL-V19-50 (Scratch-E)	1.99	2.66	13.88	4.07
SL-V19-70 (Scratch-E)	2.20	2.78	11.53	3.28
V16 (база)	2.67	1.77	17.82	3.35
V19 (база)	3.62	2.16	20.98	4.12

Медиана медиан по 5 повторам, FP32 без TF32 и FP16, CUDA events. Нерегулярные маски не мерялись: плотное ядро от маски не ускоряется. На batch 1 ResNet-56 упирается в запуск ядер, а не в FLOPs: прунинг 80% даёт 6.2 мс против 7.4 мс у базы. На batch 256 разница заметна: 9.5 мс против 16.5 мс.



5. Проверка гипотез

Гипотеза	Вердикт	Данные
H1	подтверждена	SB−FT: L1-V16A +0.34, L1-R56A -0.18, L1-R56B +1.14, SL-V19-70 +0.68, SL-R56-60 +1.72
H1c	не проверено	WT-прогоны вырезаны бюджетом
H2, SB>SE	подтверждена	13 из 15 пар с E_B>160
H2, кривая	подтверждена	SB−FT на SL-R56: 40%: +0.87, 60%: +1.72, 80%: +4.37. Прогон без потолка 2× не запускался
H3, VGG	подтверждена	SL−UF: 30%: +0.70, 50%: +1.88, 70%: +2.27
H3, guided	не проверено	GD-прогоны вырезаны бюджетом
H3, ResNet	опровергнута	|SL−UF|: 40%: 0.28, 60%: 2.16, 80%: 2.22
H4	опровергнута	UN-V19-80 SB−FT +0.65; UN-R56-95 SB−FT +1.69

Вердикт «не проверено» значит, что прогоны для критерия не запускались. Это не подтверждение и не опровержение. Выводы по H1, H2 и H3 (VGG) опираются на 2 сида для основных конфигов и 1 сид для остальных; std между сидами в основном 0.1–0.9 п.п., то есть сопоставим с критериями в 0.2–0.3 п.п. Поэтому «подтверждена» для H1 следует читать как «согласуется со статьёй», но не как статистически строгое доказательство.

6. Отклонения от статьи и ограничения

- Охват: только CIFAR-10 и VGG-16/19, ResNet-56. Не воспроизводились ImageNet, ThiNet, Regression, SSS, SFP, PreResNet, DenseNet, детекция, CIFAR-100 и transferred guided.
- Сиды: 2 у основных конфигов (L1×3, SL-V19-70, SL-R56-60), 1 у остальных; в статье 5. Сид 3 и все прогоны, зависящие от него, вырезаны по бюджету GPU.
- Вырезано бюджетом: сиды 2–3 у вторичных конфигов, CIFAR-100, guided pruning, winning ticket, UN-R56-80, Scratch-B без потолка 2×. Порядок и правило резки зафиксированы заранее.
- Конфиги L1-V16A*, L1-R56A*, L1-R56B* восстановлены нами: числа не сопоставимы с таблицей 1 по абсолютной величине.
- Доля прунинга ResNet-56 считается только по внутренним каналам блоков, поэтому не сравнима с таблицами 4 и 18.
- Scratch-B ограничен 2× (в статье такой потолок описан только для ImageNet). Для SL-R56-80 неограниченный вариант не запускался.
- Протокол fine-tune для Slimming в PDF не описан; мы применили тот же, что и для остальных: 40 эпох, постоянный lr 0.001, выбранный на dev-сплите.
- Обучение в bf16 с автокастом; оценка в FP32. На dev разница bf16/FP32 −0.14 п.п.
- Базовые VGG на тесте ниже статьи на 0.7–0.8 п.п., ResNet-56 на 0.1 п.п. Причину не выясняли.
- Стоимость fine-tune не входит в сравнение бюджетов, как и в статье. Scratch-B получает до 2× эпох базы, поэтому сравнение SB с FT не равное по вычислениям.

7. Выводы

Главное утверждение статьи для структурированного прунинга воспроизводится на CIFAR-10: во всех пяти основных конфигах Scratch-B не уступает fine-tune больше чем на 0.2 п.п., а в четырёх из пяти превосходит его; на ResNet-56 разрыв растёт с долей прунинга. Архитектура, найденная Slimming на VGG-19, даёт больше точности на параметр, чем uniform. Не воспроизвелось «исключение» для нерегулярного прунинга при 95% на ResNet-56 (наш Scratch-B выше fine-tune), и паритет Slimming с uniform на ResNet. Эти два расхождения мы объясняем различием в архитектурах и

недообучением fine-tune, но не проверяли. Winning ticket и guided pruning не проверены.

8. Воспроизводимость

Гиперпараметры зафиксированы тегом git hparams-v1 (хэш 52a438d6f5dbe86a). Все числа таблиц сгенерированы из report/tables/*.csv|json (src.aggregate, scripts/latency.py); числа статьи лежат в report/paper_tables.json и перенесены из PDF. Инварианты агрегатора (все прошли): одинаковый хэш гиперпараметров во всех прогонах, число эпох и вехи lr по плану, одна оценка на тесте, E_B в Scratch-B равно рассчитанному, разные init-отпечатки у разных сидов и у Scratch-E против fine-tune, нет полей best_*. Тесты в tests/ проходят полностью без пропусков. Команды запуска см. в README.MD.

Бюджет GPU: допуск 16.8 ч, включено прогонов 79 из 181, вырезано 102.

Приложение. Все результаты на тесте (последняя эпоха, mean ± std по сидам)

Конфиг	Режим	n	Точность, %	Параметров	MAC
L1-R56A	FT	2	92.42±0.42	597526	87054976
L1-R56A	SB	2	92.25±0.80	597526	87054976
L1-R56A	SE	2	91.70±0.87	597526	87054976
L1-R56B	FT	2	91.14±0.33	360142	63185536
L1-R56B	SB	2	92.28±0.59	360142	63185536
L1-R56B	SE	2	91.84±0.34	360142	63185536
L1-V16A	FT	2	92.89±0.33	5261866	206146048
L1-V16A	SB	2	93.23±0.12	5261866	206146048
L1-V16A	SE	2	93.08±0.09	5261866	206146048
R56	BASE	2	93.03±0.13	853018	125485696
R56	BASES	2	93.07±0.36	853018	125485696
SL-R56-40	FT	1	92.00	448438	84492928
SL-R56-40	SB	1	92.87	448438	84492928
SL-R56-40	SE	1	92.47	448438	84492928
SL-R56-60	FT	2	90.88±0.56	273942	60549760
SL-R56-60	SB	2	92.59±0.36	273942	60549760
SL-R56-60	SE	2	91.18±0.69	273942	60549760
SL-R56-80	FT	1	86.54	121482	35334784
SL-R56-80	SB	1	90.91	121482	35334784
SL-R56-80	SE	1	90.36	121482	35334784
SL-V19-30	SE	1	92.87	9514008	261984102
SL-V19-50	SE	1	93.19	4960913	200462804
SL-V19-70	FT	2	92.73±0.01	2024834	162499802
SL-V19-70	SB	2	93.41±0.22	2024834	162499802
SL-V19-70	SE	2	93.12±0.33	2024834	162499802
UF-R56-40	UF	1	92.19	453328	65544832
UF-R56-60	UF	1	89.51	278818	40163968
UF-R56-80	UF	1	88.14	119464	16718464
UF-V19-30	UF	1	92.17	9519543	188994314
UF-V19-50	UF	1	91.31	4970091	99150726
UF-V19-70	UF	1	90.62	2031499	40458574
UN-R56-95	FT	1	87.30	47129	11130176
UN-R56-95	SB	1	88.99	47129	11130176
UN-R56-95	SE	1	88.13	47129	11130176
UN-V19-80	FT	1	92.90	4019914	209242052
UN-V19-80	SB	1	93.55	4019914	209242052
UN-V19-80	SE	1	93.27	4019914	209242052
UN-V19-95	FT	1	92.56	1017082	103076996
UN-V19-95	SB	1	93.01	1017082	103076996
UN-V19-95	SE	1	92.87	1017082	103076996
V16	BASE	2	92.84±0.41	14724042	313201664
V19	BASE	1	92.84	20035018	398136320
V19	BASES	2	92.68±0.20	20035018	398136320