Воспроизведение: Rethinking the Value of Network Pruning

Liu, Sun, Zhou, Huang, Darrell. ICLR 2019, arXiv:1810.05270. Отчёт собран из CSV, числа не переписывались вручную.

Тезис

Для структурированного прунинга дообучение унаследованных весов не лучше, чем обучение той же архитектуры с нуля при сопоставимом бюджете. Ценность прунинга — в архитектуре. Нерегулярный magnitude-прунинг на высокой разреженности — исключение. ImageNet в эту работу не входит.

Протокол

Один цикл обучения. База 160 эпох, SGD Nesterov, momentum 0.9, weight decay 1e-4, batch 128, lr 0.1, спады в 50% и 75% эпох. Fine-tune: 40 эпох, постоянный lr. Scratch-E: 160 эпох, инициализация He. Scratch-B (cap 2×): E_B = 4 * round(160 * min(2, F_L/F_P) / 4). Стоимость fine-tune в сравнение бюджетов не входит. FLOPs в таблицах — это MAC, без BN, ReLU, пулинга и сложений. Отчётная точность — последняя эпоха, не лучший чекпоинт.

Замороженные гиперпараметры

Файл conf/frozen_hparams.json отсутствует: волна на полном тесте не запускалась.

Отклонения от статьи

Конфиги L1-V16A*, L1-R56A*, L1-R56B* помечены звёздочкой: точные слои и доли в PDF не заданы. Доля каналов ResNet считается только по внутренним каналам блоков и не сопоставима с Table 4. Scratch-B ограничен двумя разами; для SL-R56-80 есть отдельный прогон без потолка (SBU). Рисунок 3 построен на VGG-19, guided — только на CIFAR-10. Три сида вместо пяти. Протокол fine-tune для Slimming в PDF не описан; здесь он тот же, что и для остальных методов.

Dev-split, не тест

dev/summary.csv нет.

Тест, mean±std по сидам

Полных прогонов нет.

Гипотезы

H1 (Scratch-B и Scratch-E против fine-tune): не проверено.

L1-V16A: SB−FT нет прогона п.п., SE−FT нет прогона п.п.

L1-R56A: SB−FT нет прогона п.п., SE−FT нет прогона п.п.

L1-R56B: SB−FT нет прогона п.п., SE−FT нет прогона п.п.

SL-V19-70: SB−FT нет прогона п.п., SE−FT нет прогона п.п.

SL-R56-60: SB−FT нет прогона п.п., SE−FT нет прогона п.п.

H1c (winning ticket против Scratch-E при lr 0.1): не проверено.

L1-V16A: WT−SE нет прогона п.п.

L1-R56A: WT−SE нет прогона п.п.

L1-R56B: WT−SE нет прогона п.п.

H2, доля пар с E_B>160, где SB−SE ≥ +0.1 п.п.: не проверено (0/0).

H2, кривая SL-R56 40/60/80, Scratch-B cap 2×: не проверено.

SL-R56-40: SB−FT нет прогона п.п.

SL-R56-60: SB−FT нет прогона п.п.

SL-R56-80: SB−FT нет прогона п.п.

SBU−FT на SL-R56-80 (без потолка, контроль): нет прогона п.п.

H3, VGG Slimming против uniform: не проверено.

VGG 30%: SL−UF нет прогона п.п.

VGG 50%: SL−UF нет прогона п.п.

VGG 70%: SL−UF нет прогона п.п.

H3, guided: не проверено.

GD 30%: GD−UF нет прогона, GD−SL нет прогона

GD 50%: GD−UF нет прогона, GD−SL нет прогона

GD 70%: GD−UF нет прогона, GD−SL нет прогона

H3, ResNet |SL−UF|: не проверено.

ResNet 40%: |SL−UF| нет прогона п.п.

ResNet 60%: |SL−UF| нет прогона п.п.

ResNet 80%: |SL−UF| нет прогона п.п.

H4: не проверено. UN-V19-80 SB−FT нет прогона п.п., UN-R56-95 SB−FT нет прогона п.п.

Доли сохранённых каналов, сид 1, Scratch-E

Нет архитектур.

Латентность GPU

Замеры после обучения, FP32 с выключенным TF32 и FP16, batch 1 и 256. Нерегулярные маски не мерялись: плотное ядро от маски не ускоряется.

latency.csv нет.

Бюджет

G1: t_ep={'resnet56': 10.141712714001187, 'vgg16': 3.847704148498451, 'vgg19': 4.610895606001577}, phi=1.0, K=1, peak_mb=None.

Инварианты

Проверки агрегатора прошли.