Rethinking the Value of Network Pruning

- Liu, Sun, Zhou, Huang, Darrell. ICLR 2019, arXiv:1810.05270
- Разбор статьи: что утверждают авторы, как проверяют и что из этого следует
- В конце: что получилось при моём воспроизведении на CIFAR

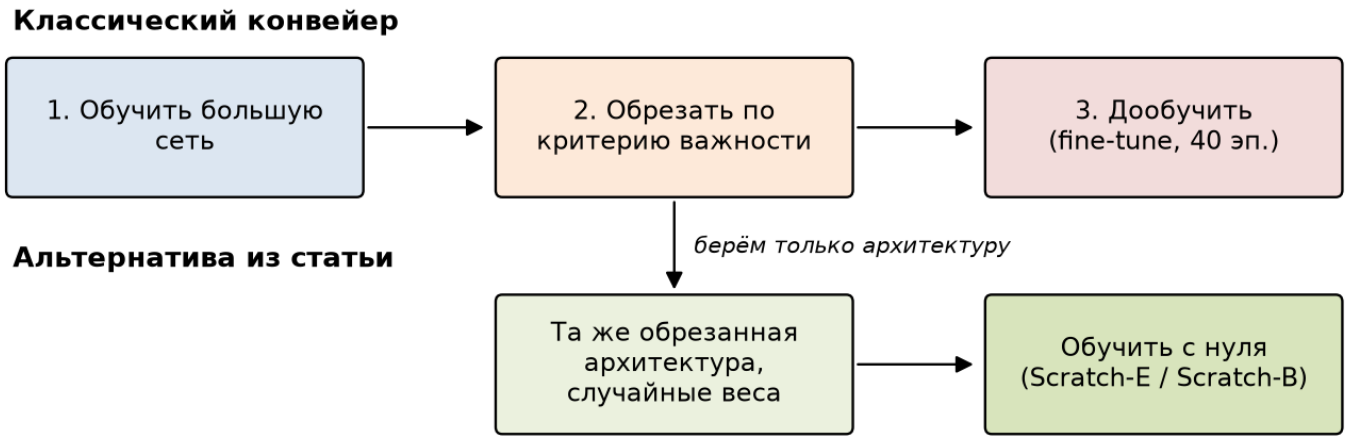
О чём статья

- Вопрос: нужны ли в прунинге сами унаследованные веса большой сети?
- Привычный ответ: да. Обучить большую сеть, убрать «ненужное», дообучить остаток.
- Ответ статьи для структурированного прунинга: нет. Та же обрезанная архитектура, обученная с нуля из случайных весов, даёт не хуже.
- Следствие: ценность прунинга — в найденной архитектуре (число каналов в слоях), а не в весах.
- Исключение, которое авторы честно указывают: нерегулярный (поэлементный) прунинг на ImageNet и очень высокой разреженности.

Классический конвейер и две общие веры

• Вера 1: сначала нужна большая перепараметризованная сеть, из неё безопасно убирать лишнее, и это лучше обучения малой сети с нуля.

• Вера 2: важны и архитектура, и веса, которые «пережили» прунинг. Поэтому почти все методы дообучают, а не обучают заново.



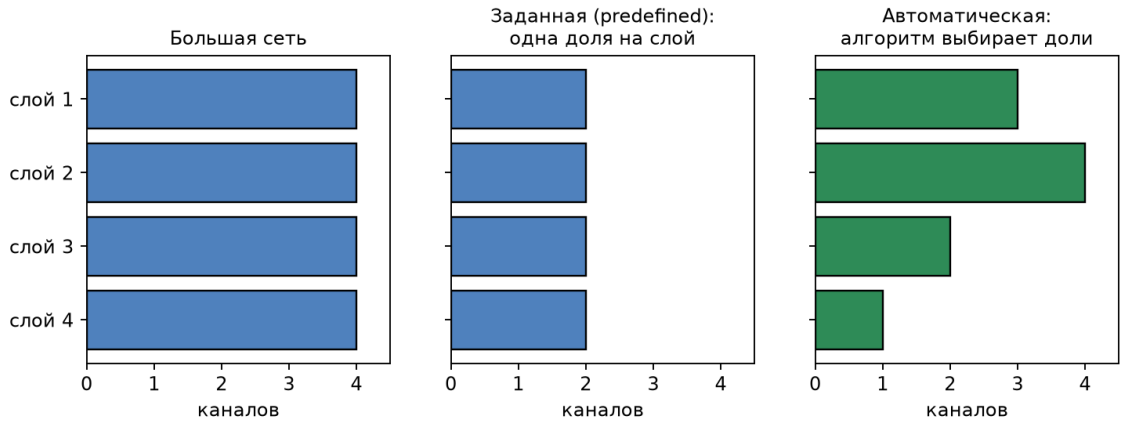
Какие бывают целевые архитектуры

• Структурированный прунинг убирает целые каналы или блоки. Остаётся обычная плотная свёртка, спецбиблиотеки не нужны.

• Нерегулярный прунинг (Han et al.) обнуляет отдельные веса. Матрицы разрежены, ускорение без специального железа не получить.

• Predefined: человек задаёт долю каналов на слой (L1-norm, ThiNet, Regression).

• Automatic: алгоритм глобально сравнивает важность и сам выбирает ширину слоёв (Network Slimming, SSS).



Как честно сравнивать с обучением с нуля

- Scratch-E: малая сеть учится столько же эпох, что и большая (160 на CIFAR). Это недоучёт: эпоха малой сети дешевле.
- Scratch-B: эпох столько, чтобы совпали FLOPs с обучением большой сети. График lr растягивается пропорционально. На ImageNet при ускорении больше 2× эпохи просто удваиваются.
- Стоимость fine-tune в бюджет не включают. Авторы отмечают, что это в пользу конвейера прунинга.
- Протокол: SGD с Нестеровым, ступенчатый lr, He-инициализация. CIFAR: 160 эпох обучения, 40 дообучения. ImageNet: 90 и 20. 5 сидов, среднее и std.
- Fine-tune идёт с самым маленьким lr большой сети. На ImageNet сравнивают относительное падение точности из-за разницы фреймворков (PyTorch против Caffe).

Что проверяли

• Predefined структурированные: L1-norm filter pruning (Li et al.), ThiNet (Luo et al.), Regression-based reconstruction (He et al.), Soft Filter Pruning (приложение).

• Automatic структурированные: Network Slimming (Liu et al.), Sparse Structure Selection (Huang, Wang).

• Нерегулярный: magnitude pruning (Han et al.), только веса свёрток.

• Данные: CIFAR-10, CIFAR-100, ImageNet. Сети: VGG, ResNet, DenseNet, PreResNet. Отдельно перенос на детекцию (приложение B).

• Запущено: L1-norm, Network Slimming, Han, uniform. Планировал, не успел: guided pruning, Lottery Ticket, CIFAR-100.

Результат 1: L1-norm, CIFAR-10 (таблица 1 статьи)

- Scratch-E в пределах 0.15 п.п. от fine-tune или выше, Scratch-B выше fine-tune во всех трёх строках (на 0.1–0.4 п.п.).
- На ImageNet (ResNet-34) оба Scratch-B лучше fine-tune заметно.

Модель	Исходная	Fine-tune	Scratch-E	Scratch-B
VGG-16-A	93.63	93.41	93.62	93.78
ResNet-56-A	93.14	92.97	92.96	93.09
ResNet-56-B	93.14	92.67	92.54	93.05

Точность на тесте, %. Среднее по 5 сидам. ResNet-110 из таблицы 1 не приведён.

Результат 2: ThiNet и Regression на ImageNet

- Показано относительное падение точности от большой сети (таблицы 2 и 3).
- Scratch-B не хуже fine-tune во всех строках. Scratch-E лучше у ResNet-50 и хуже у VGG-16 (в VGG-Tiny бюджет срезан в разы).

Модель	Fine-tune	Scratch-E	Scratch-B
ThiNet VGG-Conv	-1.23	-2.75	+0.21
ThiNet VGG-GAP	-3.67	-4.66	-2.85
ThiNet VGG-Tiny	-11.61	-14.36	-11.58
ThiNet ResNet50-30%	-6.72	-5.21	-4.56
ThiNet ResNet50-50%	-4.13	-2.82	-2.23
ThiNet ResNet50-70%	-3.10	-1.71	-1.01
Regression VGG-16-5x	-2.67	-3.46	-0.51
Regression ResNet-50-2x	-3.25	-1.55	-1.07

Результат 3: Network Slimming (таблица 4)

• Automatic прунинг: Scratch-B лучше fine-tune в 8 из 10 экспериментов, Scratch-E слегка хуже, но чаще внутри std.

Модель	Исходная	Fine-tune	Scratch-E	Scratch-B
CIFAR-10 VGG-19 70%	93.53	93.60	93.30	93.81
CIFAR-10 PreResNet-164 40%	95.04	94.77	94.70	94.90
CIFAR-10 PreResNet-164 60%	95.04	94.23	94.58	94.71
CIFAR-10 DenseNet-40 40%	94.10	94.00	93.68	94.06
CIFAR-10 DenseNet-40 60%	94.10	93.87	93.58	93.85
CIFAR-100 VGG-19 50%	72.63	72.32	71.94	73.08
CIFAR-100 PreResNet-164 40%	76.80	76.22	76.36	76.68
CIFAR-100 PreResNet-164 60%	76.80	74.17	75.05	75.73
CIFAR-100 DenseNet-40 40%	73.82	73.35	73.24	73.19
CIFAR-100 DenseNet-40 60%	73.82	72.46	72.62	72.91

Точность на тесте, %, среднее по 5 сидам.

Результат 4: нерегулярный прунинг (таблица 6)

• На CIFAR при доле до 80% Scratch-B не хуже fine-tune. При 95% fine-tune иногда лучше (PreResNet-110).

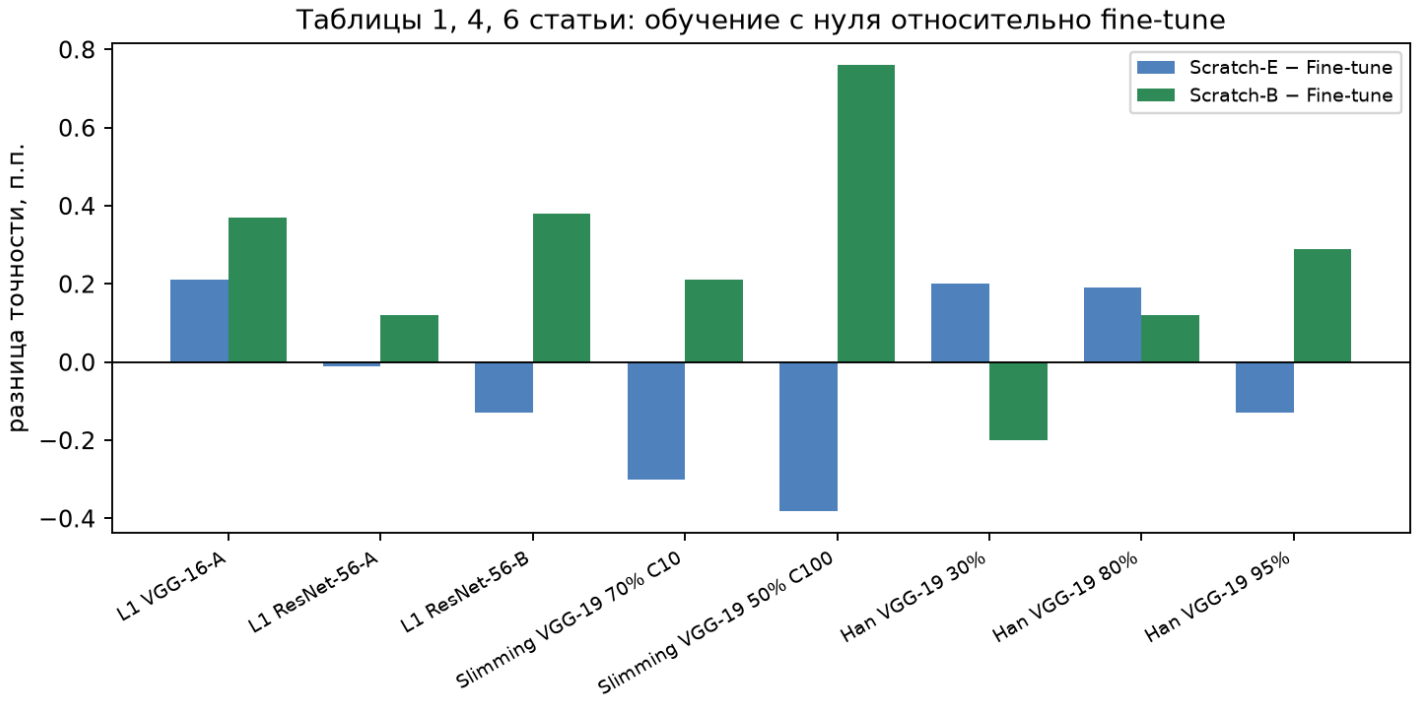
• На ImageNet Scratch-B в основном заметно хуже fine-tune. Авторы связывают это со сложностью обучения очень разреженной сети и с тем, что нерегулярный прунинг сильно меняет распределение весов.

Модель	Исходная	Fine-tune	Scratch-E	Scratch-B
VGG-19 CIFAR-10 30%	93.50	93.51	93.71	93.31
VGG-19 CIFAR-10 80%	93.50	93.52	93.71	93.64
VGG-19 CIFAR-10 95%	93.50	93.34	93.21	93.63
PreResNet-110 CIFAR-10 30%	95.04	95.06	94.84	95.11
PreResNet-110 CIFAR-10 80%	95.04	94.55	93.76	94.52
PreResNet-110 CIFAR-10 95%	95.04	92.35	91.23	91.55

Сводка: обучение с нуля против fine-tune

• Положительная разница Scratch-B означает, что обучение с нуля выигрывает у fine-tune.

• Scratch-B−FT в основном положительная, Scratch-E−FT знакопеременная; величины порядка десятых долей п.п.



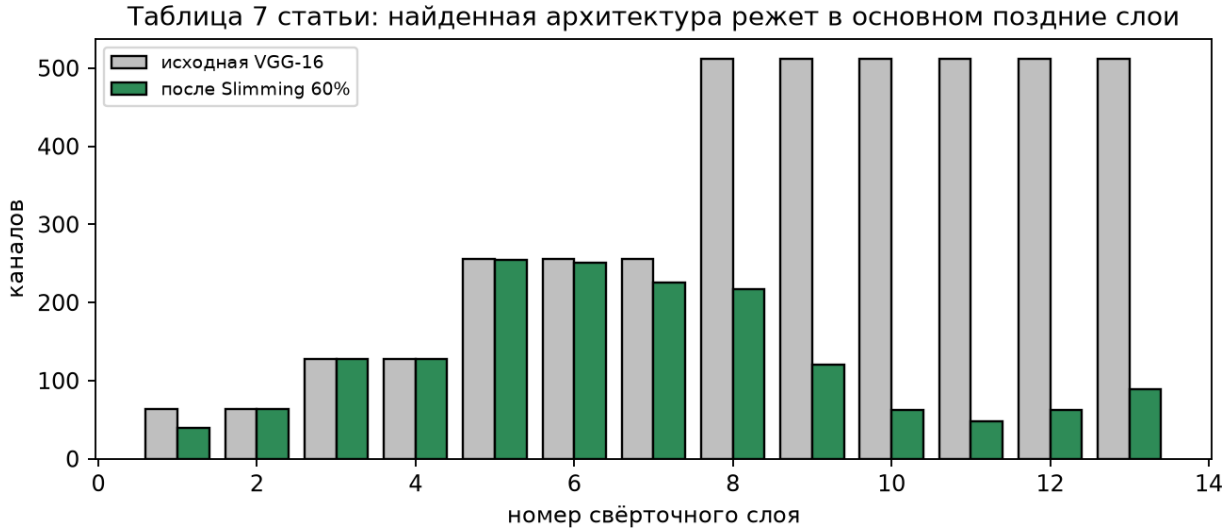
Построено по таблицам 1, 4 и 6 статьи, CIFAR.

Прунинг как поиск архитектуры

• Если веса не важны, то важна форма сети. Проверка: обучить с нуля архитектуру из прунинга и сравнить с uniform-прунингом (одна доля на все слои).

• VGG-16 на CIFAR-10 с Network Slimming: найденные архитектуры достигают той же точности с примерно в 5 раз меньшим числом параметров, чем uniform (рис. 3).

• Найденные ширины стабильны между сидами и систематичны: почти не режутся ранние слои, сильно режутся поздние (таблица 7).



Когда архитектура не лучше uniform. Guided и перенос

- У PreResNet-164 (Slimming) и у PreResNet-110, DenseNet-40 (нерегулярный прунинг) найденные архитектуры почти равномерны по стадиям (таблицы 18–20). Там прунинг не лучше uniform (рис. 5).
- У VGG избыточность неравномерна (таблица 21), и найденная архитектура всегда лучше uniform.
- Guided pruning: взять среднее число каналов по стадиям из найденных архитектур и построить из этого сеть. Она не уступает найденной (рис. 6).
- Transferred guided: шаблон из VGG-16 на CIFAR-10 переносится на VGG-19 на CIFAR-100 и всё равно заметно лучше uniform. Большую сеть для такого дизайна учить не нужно.

Lottery Ticket Hypothesis (раздел 6)

• Гипотеза: подсеть с исходной инициализацией («выигрышный билет») обучается лучше, чем та же подсеть со случайными весами.

• Авторы: при lr 0.1, стандартном для CIFAR и ImageNet, выигрыша нет. Он появляется только при малом lr 0.01, но тогда итоговая точность ниже.

• Для структурированного прунинга (L1-norm) билет не помогает ни при каком lr (таблица 8).

Доля	Winning ticket, lr 0.1	Случайная инициализация, lr 0.1	Winning ticket, lr 0.01	Случайная инициализация, lr 0.01
20%	93.66	93.79	92.78	92.52
40%	93.79	93.77	92.80	92.52
60%	93.60	93.72	92.72	92.44
80%	93.74	93.72	92.75	92.07
95%	93.18	93.05	92.58	91.83

VGG-16, CIFAR-10, одношаговый нерегулярный прунинг, таблица 9.

Выводы статьи и практика

- Для структурированного прунинга сильная базовая линия — обучить целевую архитектуру с нуля. Любое новое сравнение должно её включать.
- Обучение с нуля проще: не нужны критерий прунинга, настройка его гиперпараметров и этап дообучения; модель меньше, значит и память меньше.
- Fine-tune всё равно удобен, если большая обученная модель уже есть, а бюджета на обучение нет, или если нужно сразу несколько размеров.
- Нерегулярный прунинг на большом масштабе ведёт себя иначе: веса там могут быть важнее.

Что слабо в статье

• Часть целевых архитектур в оригинальных работах задана неполно, поэтому их приходится восстанавливать.

• Бюджет Scratch-B равен обучению большой сети без fine-tune, то есть меньше полного конвейера (обучение + fine-tune). Авторы называют это уступкой в пользу прунинга.

• Возражение «fine-tune 40 эпох мало» снято в приложении D статьи: в таблице 16 fine-tune 80 и 160 эпох заметного прироста не дают.

• Результаты на CIFAR отличаются на десятые доли п.п., а std такого же порядка. Выводы статистические, а не «железные».

• ImageNet показывает исключение для нерегулярного прунинга, но не объясняет его до конца.

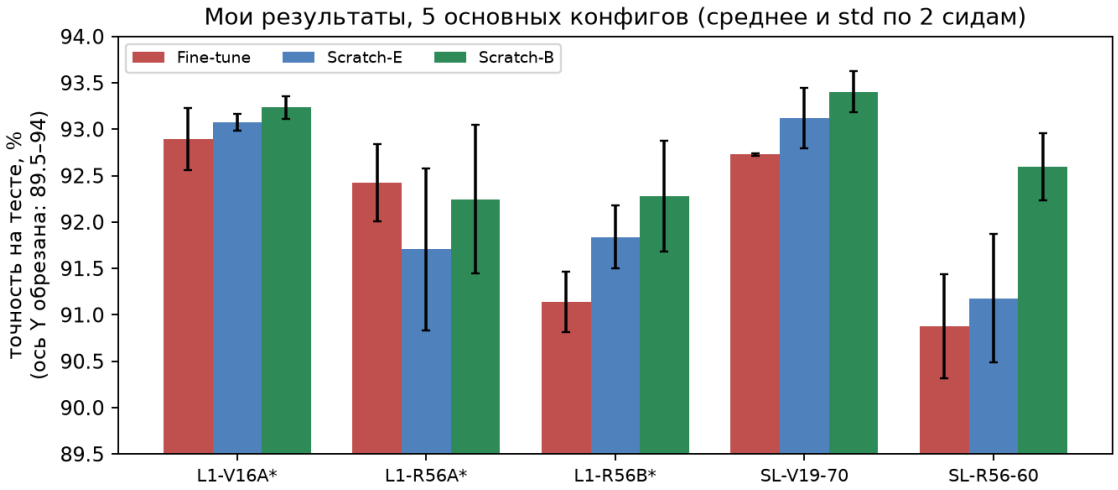
• Это моя оценка, а не цитата из статьи.

Моё воспроизведение: что я сделал

- Одна RTX 5070 Ti, один общий цикл обучения для всех режимов, гиперпараметры заморожены на dev-сплите до запуска тестов.
- Сети: VGG-16/19 и ResNet-56 на CIFAR-10. L1-norm, Network Slimming, Han, uniform. Три конфига L1 (VGG-16-A, ResNet-56-A/B) в статье заданы неполно, я восстановил их сам и пометил звёздочкой.
- Основные 5 конфигов прошли по 2 сида, остальные по 1. Статья: 5 сидов.
- Не успел по бюджету GPU: сид 3, CIFAR-100, guided pruning, winning ticket, Scratch-B без потолка 2×.

Воспроизведение: Scratch-B не хуже fine-tune

- Критерий H1 (SB−FT ≥ −0.2 п.п. в 4 из 5 и SE−FT ≥ −0.3 в 3 из 5): подтверждена.
- Хуже всего L1-R56A*: SB−FT = -0.18 п.п. Лучше всего SL-R56-60: SB−FT = +1.72 п.п.
- n=2, std 0.01–0.87 п.п. (по 5 конфигам и трём режимам) сопоставим с порогами критерия, поэтому «подтверждена» читать как «согласуется со статьёй». Ось Y на графике обрезана.



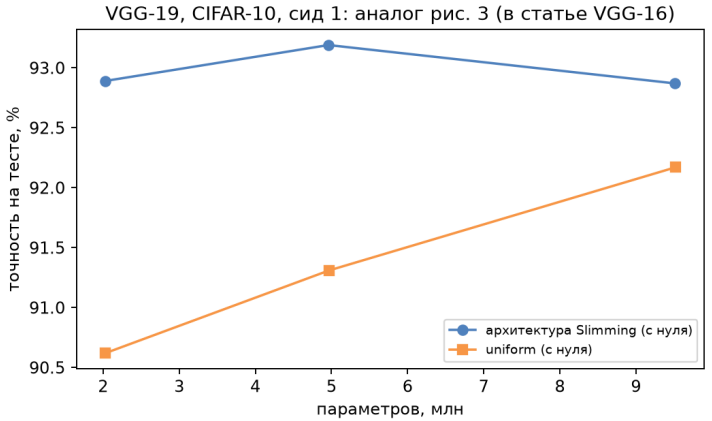
Воспроизведение: архитектура против uniform

• VGG-19, критерий H3: подтверждена. SL−UF (сид 1) = +0.70, +1.88, +2.27 п.п. при 30/50/70%. Это аналог рис. 3 на VGG-19 (в статье рис. 3 построен на VGG-16).

• Поздние стадии режутся сильнее, как в таблице 21 статьи (VGG-16).

• В статье паритет со Slimming виден на PreResNet-164 (рис. 5 слева, таблица 18); Slimming на ResNet-56 там нет. Паритет нерегулярного прунинга с uniform — на PreResNet-110 и DenseNet-40 (рис. 5 справа и в центре).

• У меня на ResNet-56 разрыв SL−UF остаётся (сид 1; 40/60/80%: 40%: +0.28, 60%: +2.16, 80%: +2.22): ширины неравномерны, размах по стадиям 0.37–0.39. Вердикт H3 для ResNet: опровергнута.



Воспроизведение: что не совпало со статьёй

- Абсолютная точность базовых VGG на тесте ниже статьи на 0.7–0.8 п.п., у ResNet-56 на 0.1 п.п.; причину не установил. Сравнение внутри моего цикла остаётся честным.
- H4 опровергнута: на ResNet-56 при 95% нерегулярный Scratch-B выше fine-tune на +1.69 п.п. H4 опиралась на перенос поведения PreResNet-110 на ResNet-56; это моё допущение, а не результат статьи.
- Предполагаю (не проверял): fine-tune 40 эпох на сильно разреженной сети недообучается.
- Winning ticket и guided pruning в итог не вошли: эти прогоны вырезаны бюджетом.

Итоги

- Главный тезис для структурированного прунинга воспроизвёлся на CIFAR-10: обучение с нуля при бюджете Scratch-B не хуже fine-tune, а чаще лучше.
- Архитектура, найденная Slimming на VGG-19, лучше uniform при том же числе параметров.
- Исключение для нерегулярного прунинга в статье — ImageNet и 95% на PreResNet-110 и DenseNet-BC-100; их я не проверял. На VGG-19 95% и у статьи, и у меня Scratch-B ≥ fine-tune. Мой аналог на ResNet-56 (H4) опровергнут: SB−FT +1.69 п.п.
- Полный отчёт со всеми таблицами, отклонениями и ограничениями: report/report.pdf.