Rethinking the Value of Network Pruning

Воспроизведение arXiv:1810.05270 на CIFAR-10/100.
Сравнение fine-tune, Scratch-E и Scratch-B (cap 2×), а не абсолютная точность.

Тезис

Структурированный прунинг ценен архитектурой, а не унаследованными весами.
При честном бюджете обучение с нуля не хуже дообучения.
Нерегулярный прунинг на 95% — ожидаемое исключение.

Что сравниваем

BASE 160 эпох → прунинг каналов или маска → FT 40 эпох.
Scratch-E: та же архитектура, 160 эпох, He init.
Scratch-B (cap 2×): эпохи подогнаны под FLOPs исходной сети, потолок к=2.
Uniform и guided — контрольные архитектуры с тем же числом параметров.

Честность

Один train loop. Отличаются инициализация, длина и расписание lr.
Точность — последняя эпоха. Тест читается один раз.
Гиперпараметры заморожены до волны и не подкручиваются по тесту.
hash=52a438d6f5dbe86a, precision=bf16, lr_ft=0.001.

Где мы отошли от PDF

L1-V16A*, L1-R56A*, L1-R56B*: слои не заданы в статье.
Доля ResNet — только внутренние каналы, это не Table 4.
Scratch-B с потолком 2×; SBU — контроль без потолка.
VGG-19 вместо VGG-16 для кривой Slimming. n=3, не 5. ImageNet нет.

Sanity на val, не на тесте

dev-V16.BASE.s0: 92.6800 (статья 93.63, gap -0.9500)
dev-V19.BASE.s0: 92.5800 (статья 93.53, gap -0.9500)
dev-R56.BASE.s0: 92.2000 (статья 93.14, gap -0.9400)
dev-V19C100.BASE.s0: 70.3600 (статья 72.63, gap -2.2700)
dev-V16.BASE.fp32.s0: 92.8200 (статья 93.63, gap -0.8100)

H1. Пять основных конфигов

L1-V16A: SB−FT 0.34, SE−FT 0.18
L1-R56A: SB−FT -0.18, SE−FT -0.72
L1-R56B: SB−FT 1.14, SE−FT 0.70
SL-V19-70: SB−FT 0.68, SE−FT 0.39
SL-R56-60: SB−FT 1.72, SE−FT 0.30

H1. Вердикт

H1: подтверждена.

Правило: SB−FT ≥ −0.2 п.п. хотя бы в 4 из 5 и SE−FT ≥ −0.3 хотя бы в 3 из 5.

Опровержение: SB ниже FT на 0.5 п.п. хотя бы в двух конфигах.

H1c, |WT−SE| < 0.3 на L1 при lr 0.1: не проверено.

H2. Бюджет и кривая Slimming

Доля SB−SE ≥ +0.1 при E_B>160: подтверждена (13/15).

SL-R56 40→60→80, cap 2×: подтверждена.

SL-R56-40: SB−FT 0.87

SL-R56-60: SB−FT 1.72

SL-R56-80: SB−FT 4.37

SBU−FT: нет прогона.

H3. Архитектура, не процедура

VGG SL−UF: подтверждена.
30%: 0.70
50%: 1.88
70%: 2.27
Guided: не проверено. ResNet: опровергнута.

H4. Нерегулярный прунинг

Вердикт: опровергнута.

UN-V19-80 SB−FT: 0.65 (ожидаем ≥ −0.3).

UN-R56-95 SB−FT: 1.69 (ожидаем ≤ −0.5).

Стена времени у маски не падает: ядро остаётся плотным.

Где режутся каналы

L1-R56A: 0.688 0.688 0.703
L1-R56B: 0.688 0.406 0.406
L1-V16A: 0.750 1.000 1.000 0.500 0.500
SL-R56-40: 0.764 0.819 0.451
SL-R56-60: 0.625 0.590 0.253
SL-R56-80: 0.493 0.267 0.104
SL-V19-30: 0.789 0.980 0.868 0.704 0.572
SL-V19-50: 0.703 0.973 0.786 0.518 0.268
SL-V19-70: 0.688 0.973 0.773 0.184 0.071
UN-R56-95: 1.000 1.000 1.000
UN-V19-80: 1.000 1.000 1.000 1.000 1.000
UN-V19-95: 1.000 1.000 1.000 1.000 1.000

Латентность

L1-R56A.SE.s1 bs 1 fp32: 7.3007 ms
L1-R56B.SE.s1 bs 1 fp32: 6.7155 ms
L1-V16A.SE.s1 bs 1 fp32: 1.5483 ms
R56.BASE.s1 bs 1 fp32: 7.4294 ms
SL-R56-40.SE.s1 bs 1 fp32: 6.9226 ms
SL-R56-60.SE.s1 bs 1 fp32: 6.4620 ms
SL-R56-80.SE.s1 bs 1 fp32: 6.2457 ms
SL-V19-30.SE.s1 bs 1 fp32: 2.4435 ms
SL-V19-50.SE.s1 bs 1 fp32: 1.9877 ms
SL-V19-70.SE.s1 bs 1 fp32: 2.1959 ms
V16.BASE.s1 bs 1 fp32: 2.6692 ms
V19.BASE.s1 bs 1 fp32: 3.6164 ms

Бюджет GPU

Smoke phi=1.0, K=1.

Сначала режутся хвостовые классы: лишние сиды P2a, CIFAR-100, guided, контроль 80%, SBU, winning ticket.

160/40 эпох, к=2 и оценка последней эпохи не режутся.

Вывод

H1: подтверждена. H1c: не проверено.
H2 бюджет: подтверждена. H2 кривая Slimming: подтверждена.
H3 VGG: подтверждена. H3 guided: не проверено. H3 ResNet: опровергнута.
H4: опровергнута.
Вырезанный подкритерий записан как «не проверено». Абсолютная точность ниже статьи не отменяет сравнение внутри одного цикла.